Гибридная агентная система распознавания и нормализации метаданных гербарных этикеток (OCR + VLM + Tool-Using Agent)

Постановка исследовательской задачи и программа экспериментов

Рабочий корпус: микологический гербарий Ботанического института им. В. Л. Комарова РАН, подколлекция головнёвых грибов (Ustilaginomycotina, "Smuts"). Документ построен по структуре научной статьи: введение и мотивация, обзор state-of-the-art, дизайн системы, дизайн экспериментов, метрики, риски, дорожная карта, библиография. Ссылки на литературу даны в виде [N] и приведены в разделе 11.

1. Введение и научная значимость

Биологические коллекции — материальная основа таксономии и одной из крупнейших задач биологических наук, документирования биоразнообразия Земли. По оценкам Index Herbariorum, в мире насчитывается около 3500 действующих гербариев, содержащих ~398 миллионов физических образцов сосудистых растений, мохообразных, водорослей, лишайников и грибов [1, 2]. Эти коллекции лежат в основе систематических, экологических, климатических и природоохранных исследований [3, 4] и одновременно служат верифицируемой летописью присутствия таксонов в конкретной точке пространства и времени [5, 6].

Ботанический институт им. В. Л. Комарова РАН (LE) хранит крупнейшее в России и пятое в мире гербарное собрание — более 7.3 млн образцов высушенных растений и грибов, собранных за 300 лет существования института. Микологический фонд LE (~350 тыс. образцов) является крупнейшей коллекцией грибов в России и включает многочисленные типовые сборы Ustilaginales, Uredinales и других групп.

Проблема — «dark data» в гербариях. Несмотря на колоссальную научную ценность, метаданные коллекций остаются «тёмными данными»: оцифровано в виде изображений лишь ~5 % сосудистых растений LE, тогда как для микологической части доля изображений составляет менее 1 %, а структурированные метаданные имеются только у ~22 % образцов. На глобальном уровне темпы транскрипции метаданных не растут уже более десяти лет, оставаясь главным «бутылочным горлышком» мобилизации биоразнообразия в открытые базы [7, 8, 9, 10]. Ручная транскрипция дорога, медленна и подвержена шуму от разнобоя кураторских школ и эпох. Эти данные должны соответствовать принципам FAIR (Findable, Accessible, Interoperable, Reusable) [101] и стандартам биологических данных — Darwin Core [27] и ABCD [26].

Цель исследования. Разработать и экспериментально валидировать многоступенчатую гибридную систему извлечения структурированных метаданных из изображений этикеток микологического гербария LE. Система объединяет:

1. классические state-of-the-art методы оптического распознавания текста (OCR/HTR) [11, 12, 13, 14, 15];
2. визуально-языковые модели (Vision-Language Models, VLM) как нормализаторы и структуризаторы [16, 17, 18, 19, 20, 21];
3. tool-using агента-валидатора с доступом к авторитативным таксономическим, биографическим и географическим справочникам [22, 23, 24, 25, 26].

Конечной целью является получение машиночитаемой таблицы метаданных, согласованной со стандартом **Darwin Core** [27], с per-field оценкой уверенности и журналом решений, пригодных для аудита куратором.

2. Характеристика материала и предварительный анализ

Корпус, на котором ведётся прототипирование, содержит 394 JPEG-изображения этикеток образцов с инвентарными префиксами `LE F-*` из подколлекции головнёвых грибов (Ustilaginales). Первичный визуальный анализ выявил высокую гетерогенность материала по нескольким измерениям (Таблица 1).

Таблица 1. Гетерогенность подколлекции Smuts.

Характеристика	Примеры	Сложность для распознавания
Эпохи	1898 (Sydow, Ustilagineen); 1946 (Кузнецова); 1988, 1996 (K. Vánky)	Шрифты разных эпох, выцветание, бумажные дефекты
Языки	латынь (научные названия), английский, немецкий, русский (включая дореф. орфографию)	Многоязычность, диакритика (Vánky, ä, ö), кириллица
Тип текста	типографский, машинопись, рукопись, смешанный	Рукопись требует HTR-моделей, отличных от OCR
Форматы дат	`20. 10. 1898`, `13. VI. 1946`, `26.II.1988`, `3.III.1996`	Римские/арабские цифры, разные разделители
Геолокация	устаревшие топонимы («USSR: Kazachstaniae, Alatau Transiliense»); современные координаты (42°55' S, 171°33' E)	Геокодинг исторических административных единиц
Статусные пометки	Isotypus, Holotypus (цветные стикеры)	Семантика выражена визуально, а не только текстом
Композиция	несколько этикеток в кадре, штрих-коды, разворот конверта	Требуется детекция и сегментация компонентов

Эта гетерогенность является и научной мотивацией работы: ни один из существующих прямых аналогов (см. §3) не валидирован на материале такого временно́го и лингвистического диапазона, а большинство — заточены под коллекции *растений*, использующие справочник WFO [28], а не справочники грибной номенклатуры [22, 23].

2.1. Целевая схема метаданных

Финальная схема будет уточнена совместно с микологами LE; предварительно она построена как подмножество Darwin Core [27], расширенное полями, специфичными для микологии (`host_plant`, `type_status`):

- `catalog_number` — инвентарный номер (например, `LE F-198013`);
- `barcode` — штрих-код;
- `collection_series`, `series_number` — серия (Sydow Ustilagineen; K. Vánky: Ustilaginales и пр.) и её номер;
- `scientific_name`, `taxon_authority`, `taxon_rank` — научное название гриба, автор и таксономический ранг;

- `type_status` — типовой статус (holotypus / isotypus / paratypus / —);
- `host_plant` (Matrix) — растение-хозяин (`Oreobolus strictus`, `Lepidosperma gunnii`);
- `country`, `country_modern` — страна по этикетке и современная страна (например, USSR → Kazakhstan);
- `locality_raw`, `locality_normalized` — место сбора как на этикетке и его нормализованная форма;
- `latitude`, `longitude`, `altitude_m` — координаты и высота;
- `collection_date_raw`, `collection_date_iso` — дата в исходной и нормализованной (ISO 8601) форме;
- `collector` (`leg.`), `determiner` (`det.`) — коллекторы и определители;
- `notes` — прочие пометки (например, `later homonyme`, `ex AA`, `KV: 1500`).

3. Обзор state of the art

3.1. Прямые аналоги: digitization гербариев

Hespi (Turnbull et al., 2024/2025) [21] — наиболее близкий к нашей постановке открытый пайплайн. В нём последовательно применяются: двухуровневая объектная детекция (YOLOv8 [29] для компонентов гербарного листа, затем для полей внутри primary specimen label); классификатор типа текста (ResNet-34 [30] / Swin Transformer V2 [31]); связка Tesseract [11] + TrOCR-large [13]; кросс-проверка таксонов со списками **World Flora Online** [28] и **Australian National Species List**; финальная коррекция мультимодальной LLM (GPT-4o) [16]. На печатных этикетках Hespi достигает text similarity 92.7 %, на рукописных — 88.8 %, на гетерогенном DILLEN-наборе из десяти европейских гербариев [32] — 67.1 %. Авторы прямо указывают, что LLM-коррекция даёт прирост 6–11 п.п. метрики.

Wen et al., 2025 [33] — параллельный подход: связка **PaddleOCR** [12] + text-only LLM **DeepSeek-V3** [34] с трёхуровневой системой confidence-тиров и 16 полями Darwin Core. На печатных растительных этикетках достигнуто 95.4 % field-level accuracy при полностью локальном inference (без отправки изображений во внешние API). Эта работа важна как естественный baseline вопроса «нужен ли мультимодальный VLM, или достаточно классического OCR + текстового LLM».

Дополнительные бенчмарки и работы: Owen et al. [9] показали, что HTR-инструменты (ABBYY FineReader, Google Cloud Vision) уже пригодны для части материала; Haston et al. [35], Drinkwater et al. [36] и Alzuru et al. [37] независимо подтвердили принцип «OCR на кадрированной этикетке точнее, чем на полном листе»; Milleville et al. [38] и Walker et al. [4] показали, что Google Cloud Vision на латинских названиях даёт лишь ~24 % полных совпадений и ~36 % частичных, что мотивирует кросс-сверку с таксономическими справочниками. Guralnick et al. [10] и Weaver et al. [39] первыми описали применение современных VLM (GPT-4V) к гербарным этикеткам и сформулировали дизайн «instructable VLM» для биоразнообразия.

3.2. Document layout и детекция

Семантическая сегментация изображения этикетки — обязательный шаг: текст распознаётся точнее, когда модель работает на кадрированной этикетке, и тем более — построчно [35, 37]. SOTA-инструменты:

- **YOLOv8** / **v10** / **v11** [29] и **RT-DETR** [40] — универсальные one-stage детекторы.
- **DocLayout-YOLO** (Zhao et al., 2024) [41] — детектор, специально предобученный на синтетическом DocSynth-300K и оптимизированный для документов; превосходит generic YOLO на бенчмарках document layout.
- **Grounding DINO** [42] + **SAM 2** [43] — open-vocabulary детекция и сегментация: позволяет находить «isotypus-стикер», «штрих-код», «штамп» без полной переразметки.

3.3. OCR и HTR

Современные OCR-движки для печатного текста: PaddleOCR PP-OCRv4 / PP-StructureV3 [12]; Surya OCR [44]; docTR (Mindee) [45]; Tesseract 5 [11, 14]; EasyOCR [15] как альтернативный baseline. Для исторического печатного материала (например, Sydow 1898) релевантны Kraken [46] и Calamari [47], позволяющие тонкий файнтюн под конкретный шрифт.

HTR (Handwritten Text Recognition). Базовая открытая модель — TrOCR-large-handwritten [13]; для исторической рукописи на кириллице и немецкой каллиграфии XIX–XX вв. практичны PyLaia [48], Kraken [46] и публичные модели платформы Transkribus [49]. В последний год SOTA сдвинулась к VLM общего назначения (Florence-2 [50], Qwen2.5-VL [17, 51]; см. также PaliGemma [20]), которые в режиме HTR показывают сравнимое или лучшее качество без необходимости отдельного датасета — за счёт огромного предобучения.

3.4. End-to-end / OCR-free document understanding

Альтернативная парадигма — «прочитать документ» одной моделью без явного OCR-шага:

- **Donut** (Kim et al., ECCV 2022) [18] — OCR-free Transformer, обучаемый напрямую от изображения к JSON.
- **Nougat** (Blecher et al., Meta, 2023) [52] — для научных страниц с формулами и таблицами.
- **GOT-OCR 2.0** (Wei et al., 2024) [19] — 580 M unified end-to-end модель, читает обычный текст, формулы, ноты, таблицы; выдаёт markdown/LaTeX.
- **Florence-2** (Microsoft, 2024) [50] — мультизадачная VLM с режимами dense OCR + region grounding.

3.5. Vision-Language Models общего назначения

- **Open-weight**: Qwen2.5-VL (7B / 32B / 72B) [17, 51]; InternVL 2.5 / 3 [53]; MiniCPM-V 2.6 [54]; Llama-3.2-Vision [55]; PaliGemma 2 [56].
- **Frontier**: GPT-4o / GPT-4.1 [16]; Claude 3.5 / 4 Sonnet [57]; Gemini 2.0 / 2.5 Pro [58].
- **Инфраструктура локального inference**: vLLM [59], SGLang [60], llama.cpp.

Бенчмарки документного понимания, релевантные нашей задаче: DocVQA [61], OCRBench v2 [62], MMDocBench [63].

3.6. Структурное извлечение в JSON

- **Constrained decoding**: Outlines [64], Instructor [65], JSON-schema-guided decoding в vLLM/SGLang — гарантируют синтаксически валидный JSON без лишних шагов парсинга.
- **NER для специфических полей**: Quaesitor [66] — распознавание латинских научных названий в тексте; GLiNER [67] — zero-shot NER для произвольных типов сущностей.
- **Парсеры дат и адресов**: dateparser, libpostal; regex-эвристики для координат в DMS-формате.

3.7. Авторитативные источники для микологии

Принципиально важно, что Hespi и Wen опираются на ботанические справочники (WFO, APNI и др.). Для грибов они бесполезны. Адекватные источники:

- **Index Fungorum** [22] и **MycoBank** [23] — канонические БД грибной номенклатуры (~500 тыс. имён каждая, с синонимикой и authorities).
- **GBIF Backbone Taxonomy** [24], **Catalogue of Life** [68], **NCBI Taxonomy** [69] — кросс-сверка.
- **Bionomia** [25] — связывает имена коллекторов и определителей с Wikidata QID, годами жизни, ORCID и реестром образцов; критично для исторических лиц (E. W. D. Holway, M. N. Kuznetzova, K. Vánky).
- **Harvard Index of Botanists (HUH)** [70] — стандартные сокращения авторов таксонов (`P. Henn.`, `Schauer` и т. п.).
- **JSTOR Global Plants** [71] и **GBIF Occurrences** [24] — поиск дубликатов одного и того же

образца в других гербариях. Для типов это особенно сильный сигнал: Iso/Holotypus, хранящийся в LE, почти всегда имеет дубликаты в S, NY, K, BPI.

3.8. Геокодинг и историческая география

Современный геокодинг: **GeoNames** [72], **Nominatim/OSM** [73], **Pelias** [74], **Wikidata SPARQL** [75]. Для исторических топонимов (USSR, Persia, Ceylon, провинции дореволюционной России): **Getty TGN** [76], **World Historical Gazetteer** [77]. Для качества координат: **CoordinateCleaner** [78] и **bdc** [79] — пакеты biodiversity-data cleaning с типовыми проверками соответствия координат и страны.

3.9. Калибровка, агентная оркестрация и валидация

- **Калибровка**: temperature/Platt scaling per-field вероятностей [80]; self-consistency для LLM [81]; LLM-as-a-judge для авто-оценки [82].
- **Оркестрация**: LangGraph [83], Pydantic-AI [84], smolagents [85], Llama-Index Agents [86]; MCP-серверы [87] под каждый внешний источник.
- **Архитектура с независимой проверкой**: разделение Extractor- и Verifier-агентов (по логике CriticGPT [88], Reflexion [89]) для снижения галлюцинаций.

3.10. Принципиальные новизны нашего исследования

В таблице 2 сведены ключевые отличия предлагаемой системы от ближайших аналогов [21, 33].

Таблица 2. Отличия от Hespi и Wen et al.

Аспект	Hespi [21]	Wen et al. [33]	Настоящая работа
Целевая группа	Сосудистые растения	Сосудистые растения	**Грибы (микология)**
Таксономический бэкенд	WFO + AusNSL	(LLM «на знаниях»)	**Index Fungorum + MycoBank**
Поле `host_plant` (Matrix)	нет	нет	**есть, нормализуется через WFO**
Поле `type_status` со стикером	нет	нет	**есть, отдельный классификатор**
Кросс-гербарная сверка дубликатов	нет	нет	**GBIF Occurrences + JSTOR**
Историческая география	нет	нет	**Getty TGN + WHGazetteer**
Биографические БД коллекторов	нет	нет	**Bionomia → Wikidata QID**
Архитектура коррекции	один проход LLM	text-only LLM	**двойной агент Extractor/ Verifier**
Калибровка и curation-free rate	нет	нет	**first-class метрика**
End-to-end VLM как ветка сравнения	нет	нет	**отдельный эксперимент (Эксп. 4)**

4. Архитектура предлагаемой системы

Система спроектирована как модульный конвейер из четырёх ступеней (Рис. 1), допускающий замену отдельных модулей независимо. Модульность важна для воспроизводимости и для использования будущих, более совершенных моделей без переписывания всей системы [21].



Рис. 1. Архитектура конвейера. Каждая ступень оценивается отдельно (см. §6), что позволяет количественно атрибутировать прирост качества компоненту.

5. Гипотезы исследования

Конкретные гипотезы, проверяемые в экспериментах:

- **H1.** Современные классические OCR-движки [11, 12, 44, 45] достигают приемлемого CER на печатных этикетках, но дают низкий F1 по структурированным полям без LLM-нормализации, и заметно деградируют на рукописи и смешанных этикетках. (соответствует наблюдениям [9, 35, 38]).
- **H2.** Мультимодальная VLM, получающая *одновременно* изображение и OCR-выдачу, существенно (≥ 10 п.п. в F1) превосходит чисто OCR-конвейер и одиночную VLM zero-shot, особенно на смешанных и рукописных этикетках [16, 17, 21].
- **H3.** Доступ агента к авторитативным справочникам [22, 23, 25, 72] даёт дополнительный прирост качества преимущественно в *нормализованных* полях (taxonID, QID, GeoNames ID) и сокращает долю записей, требующих ручной проверки куратором.
- **H4.** На печатных этикетках text-only LLM с OCR-входом [33] даёт качество, сопоставимое с multimodal VLM, при многократно меньшей стоимости; на рукописных и смешанных multimodal-режим необходим.
- **H5.** End-to-end VLM (Donut [18] / Florence-2 [50] / GOT-OCR 2.0 [19]) после файнтюна на нашей схеме конкурентоспособна с классическим конвейером на печатных этикетках и принципиально дешевле в inference.
- **H6.** Calibrated per-field confidence позволяет автоматизировать ≥ 50 % записей с точностью, превышающей точность оператора начального уровня, и направлять оставшиеся к куратору (curation-free rate metric).

6. Программа экспериментов

Эксперименты выстроены по принципу **поступательного наращивания сложности**: каждый шаг сопоставляется с предыдущим на одном «золотом» наборе, что позволяет количественно атрибутировать прирост каждому компоненту.

Эксперимент 0. Подготовка датасета и инфраструктуры оценки

Задачи.

- Сформировать «золотой» набор: ~50 → 200 → 500 этикеток с ручной разметкой по всем полям (стратифицированно по типу текста, эпохе и языку).
- Pydantic-схема [92] полей и валидатор; формат хранения — JSONL.
- Сквозной evaluation-скрипт с метриками §7.
- Документация схемы и инструкции по разметке для согласованности между разметчиками.

Эксперимент 1. Бейзлайн — классический OCR

Проверяемая гипотеза. H1.

Подэксперименты.

- 1a. Tesseract 5 [11] (rus+eng+deu+lat) без предобработки.
- 1b. Tesseract 5 + классическая предобработка (deskew, denoise, Sauvola adaptive threshold [93]).
- 1c. PaddleOCR PP-OCRv4 [12] в multilingual-режиме.
- 1d. Surya OCR [44].
- 1e. TrOCR (printed + handwritten checkpoints) [13].
- 1f. Ансамбль: голосование/выбор по confidence.

Постобработка для извлечения полей. Только эвристики/regex (поиск дат по шаблонам, заглавные слова после `leg.` / `det.`, и т. п.) — как в исторических работах [37].

Ожидаемый результат. CER приемлем для типографских этикеток (≤ 5 %), F1 по полям заметно ниже из-за слабой структуризации; на рукописных и смешанных — значительная деградация. Этот результат — нижний baseline для всей системы.

Эксперимент 2. Подключение VLM как нормализатора и структуризатора

Проверяемая гипотеза. H2.

Подэксперименты.

- 2a. VLM zero-shot, только изображение, без OCR (контрольная точка — что умеет VLM сама).
- 2b. VLM + сырой OCR-текст в промпте.
- 2c. VLM + OCR с bbox и confidence (структурированный вход).
- 2d. Few-shot с 3–5 примерами разных типов этикеток (по аналогии с GPT-3-style in-context learning [94]).
- 2e. Self-consistency [81]: k = 5 прогонов с разным сэмплированием, агрегация большинством.

Сравнение моделей. Минимум одна open-weight (Qwen2.5-VL [17]) и одна frontier (GPT-4o [16] или Claude 3.5 Sonnet [57]) — чтобы отделить эффект архитектуры от эффекта схемы.

Ожидаемый результат. Существенный рост F1 по полям, особенно на смешанных и рукописных этикетках; снижение CER за счёт визуальной коррекции; формализованный JSON-выход.

Эксперимент 3. Агентная валидация с внешним контекстом

Проверяемая гипотеза. H3.

Подэксперименты — наращивание набора инструментов:

- 3a. Агент с поиском по таксонам (**Index Fungorum** [22] / **MycoBank** [23] / **GBIF** [24]).
- 3b. + биографические БД коллекторов (**Bionomia** → **Wikidata QID** [25, 75], **HUH** [70]).
- 3c. + современный геокодинг (**GeoNames** [72], **Nominatim** [73]).
- 3d. + **исторический геокодинг** (**Getty TGN** [76], **WHGazetteer** [77]) для устаревших административных единиц.
- 3e. + **кросс-гербарная сверка дубликатов** в **JSTOR Global Plants** [71] и **GBIF Occurrences** [24] по комбинации (taxon + collector + date) — особенно мощно для типовых образцов.
- 3f. + **двойной агент Extractor/Verifier** [88, 89]: вторая LLM-инстанция, не видящая решение первой, независимо извлекает поля и сравнивает; рассогласования → флаг к ручной проверке.
- 3g. Полный агент со всеми инструментами и циклом самопроверки.

Метрики этапа. Доля исправленных ошибок, доля ложных «исправлений» (как в [21], раздел 5.4), вклад в нормализованные поля.

Ожидаемый результат. Дальнейший рост качества именно по нормализованным полям и резкое сокращение случаев, требующих ручной проверки.

Эксперимент 4. End-to-end VLM без классического OCR (контрольная ветка)

Проверяемая гипотеза. H5.

Подэксперименты.

- 4a. **GOT-OCR 2.0** [19] — выход в markdown → парсер в JSON-схему.
- 4b. **Florence-2** [50] в режиме dense OCR + region grounding.
- 4c. **Qwen2.5-VL** [17] zero-shot с JSON-schema constrained decoding [64].
- 4d. **Donut** [18], файнтюненный на ~500–1000 наших разметок под целевую JSON-схему.
- 4e. Сравнение с лучшим режимом Эксп. 2 на одном gold-наборе.

Ожидаемый результат. Понимание, где end-to-end уже конкурирует с конвейером (вероятно, печатные этикетки Vánky), а где OCR-связка ещё необходима (старая рукопись на кириллице, мульти-этикеточные кадры).

Эксперимент 5. Text-only LLM vs Multimodal VLM (по мотивам [33])

Проверяемая гипотеза. H4.

Подэксперименты.

- 5a. PaddleOCR + **DeepSeek-V3** [34] (text-only) — воспроизведение пайплайна Wen [33].
- 5b. PaddleOCR + **Qwen2.5-72B-Instruct** [51] (text-only, локально через vLLM [59]).
- 5c. Та же этикетка → **Qwen2.5-VL** (multimodal).
- 5d. Стратифицированное сравнение по подмножествам: printed / typed / handwritten / mixed.
- 5e. Анализ Pareto-границы: качество vs latency vs cost.

Ожидаемый результат. Карта «когда multimodal стоит своих денег» — фундаментальный практический результат для масштабирования на 350 тыс. этикеток.

Эксперимент 6. Сводный анализ и абляции

- Сравнение четырёх режимов (OCR / OCR+VLM / OCR+VLM+Agent / E2E-VLM) на одном gold-наборе.
- Абляции: вклад каждого инструмента агента; чувствительность к выбору VLM; влияние объёма OCR-входа.
- Анализ остаточных ошибок (failure modes): на каких категориях этикеток система всё ещё проигрывает человеку?
- Экономика: latency и стоимость каждого режима в пересчёте на 1 этикетку и 350 тыс. этикеток.

Эксперимент 7. Калибровка уверенности и curation-free rate

Проверяемая гипотеза. H6.

Подэксперименты.

- 7a. Per-field confidence из VLM (logprob по полю) + temperature/Platt scaling [80].
- 7b. Self-consistency [81]: k прогонов VLM, дисперсия как мера неуверенности.
- 7c. **LLM-as-a-judge** [82]: отдельная модель оценивает «правильно ли мы извлекли», возвращает score 0–1.
- 7d. Построение reliability-диаграмм и ROC «уверенность vs корректность».
- 7e. Расчёт **curation-free rate**: при пороге т — какая доля записей не требует ручной правки, и какова при этом фактическая корректность оставшихся.

Эксперимент 8. Активное обучение и итеративное расширение gold-набора

Подэксперименты.

- 8a. Старт с 50 размеченных этикеток.
- 8b. На каждой итерации: прогон системы, расчёт неуверенности (Эксп. 7), выбор top-k неуверенных для разметки по принципам uncertainty sampling [95] с использованием инструментов вроде modAL [96].
- 8c. Дообучение детекторов; пополнение few-shot пула VLM.
- 8d. Кривая «качество vs объём разметки» — сравнить с random sampling baseline.

Эксперимент 9. Файнтюн end-to-end VLM на собственной схеме и дистилляция

Подэксперименты.

- 9a. Подготовка обучающего набора (image → JSON) из верифицированных записей предыдущих экспериментов.
- 9b. LoRA-файнтюн [97] Qwen2.5-VL-7B на нашей схеме.
- 9c. Полный файнтюн Donut [18].
- 9d. Сравнение с frontier-агентом по качеству, latency, cost.
- 9e. **Дистилляция** [98]: учитель — полный агент с инструментами, ученик — компактная локальная VLM.

7. Метрики оценки

Метрики выбраны с расчётом на (а) сопоставимость с литературой (Hespi [21], Wen [33]), (б) интерпретируемость для куратора и (в) экономическую интерпретируемость при масштабировании.

Текстовые (символьный и пословный уровень):

- CER (Character Error Rate), WER (Word Error Rate) по всему тексту этикетки.
- CER/WER отдельно по типографскому и рукописному фрагментам.

Полевые (на уровне извлечённой записи):

- Per-field exact match accuracy.
- Per-field F1 (для составных полей: список коллекторов).
- Per-field Gestalt/Ratcliff–Obershelp similarity [99] — для прямой сопоставимости с Hespi [21].

Нормализованные (entity-resolution):

- Научное название — попадание в правильный **taxonID Index Fungorum** / **MycoBank**.
- Дата — точность ISO-8601.
- Коллектор / определитель — попадание в правильный **Wikidata QID** через Bionomia.
- Геолокация — попадание в правильный **admin-0** / **admin-1** регион (через GeoNames ID) и расстояние до эталонной точки.
- `host_plant` — попадание в правильный **WFO taxonID**.

Системные:

- **Curation-free rate(т)** — доля записей, не требующих ручной правки при пороге уверенности т.
- ROC/PR-кривая «уверенность vs корректность».
- **Latency и cost per record**; экстраполяция на 350 тыс. этикеток.
- **Energy per record** (kWh) для on-prem конфигураций.

Кросс-валидационные:

- **Duplicate-consistency**: для образцов с дубликатами в GBIF/JSTOR — доля полей, согласованных с дубликатом.
- **Internal-consistency**: годы жизни коллектора $\supseteq$ дата сбора; locality $\in$ country.

Экспертные:

- Слепая оценка куратором БИН РАН на N образцах — для системы и для человека-оператора начального уровня (human baseline).

8. Риски и ограничения

- **Малый объём gold-разметки** ⇒ риск переоценки на узком наборе; смягчается стратификацией и итеративным расширением (Эксп. 8).
- **Стоимость VLM и агента** при масштабировании на 350 тыс. этикеток — необходимо измерять и предусматривать каскад «дёшево → дорого» с роутингом по confidence (Эксп. 7); смягчается также дистилляцией (Эксп. 9).
- **Галлюцинации VLM** [100] — особенно опасны для таксонов и коллекторов; смягчаются обязательной сверкой со справочниками в агентном слое (Эксп. 3) и Verifier-агентом.
- **Воспроизводимость** — фиксируем версии моделей, seed-ы, снапшоты внешних БД.
- **Этика, атрибуция и FAIR-принципы** [101] — корректное цитирование коллекторов и определителей через Bionomia; уважение к данным БИН РАН; публикация только тех полей, на которые получено согласие института.

9. Дорожная карта

1. **Эксп. 0** — подготовка gold-набора (50 → 200 → 500) и инфраструктуры оценки.
2. **Эксп. 1** — классический OCR-бейзлайн (Tesseract / PaddleOCR / Surya / TrOCR + ансамбль).
3. **Эксп. 2** — VLM-надстройка (open-weight + frontier; zero-/few-shot; self-consistency).
4. **Эксп. 3** — агент-валидатор с инструментами (Index Fungorum/MycoBank, Bionomia, GeoNames + WHGazetteer, GBIF/JSTOR кросс-сверка, Extractor/Verifier).
5. **Эксп. 4** — end-to-end VLM (GOT-OCR2, Florence-2, Donut, Qwen-VL) как контрольная ветка.
6. **Эксп. 5** — text-only LLM vs multimodal VLM на разных подмножествах.
7. **Эксп. 6** — сводный анализ и абляции.
8. **Эксп. 7** — калибровка уверенности и curation-free rate.
9. **Эксп. 8** — активное обучение, расширение gold до production-набора.
10. **Эксп. 9** — файнтюн собственной on-prem VLM и дистилляция агента.
11. Пилотный прогон на полной коллекции Smuts (394 образца); отчёт для БИН РАН.
12. Масштабирование на полную микологическую коллекцию (~350 тыс. образцов).

10. Литература

1. Thiers B. *Index Herbariorum: A global directory of public herbaria and associated staff.* New York Botanical Garden. https://sweetgum.nybg.org/science/ih/ (accessed 2024).
2. Funk V. A., Gostel M., Devine A. et al. *Guidelines for the preparation of digitized natural history collections data.* PhytoKeys, 2018.
3. Lacey E. A., et al. *Climate change, collections and the classroom.* CBE Life Sciences Education, 2017.
4. Davis C. C. *The herbarium of the future.* Trends in Ecology & Evolution, 2023.
5. Kirchhoff A., Bourlat S. J., et al. *Toward a sustainable digital infrastructure for natural history collections.* Database, 2018.
6. Groom Q., et al. *Improved standardization of transcribed digital specimen data.* Database, 2019.
7. Vollmar A., Macklin J. A., Ford L. *Natural history specimen digitization: challenges and concerns.* Biodiversity Informatics, 2010.
8. Walton S., Livermore L., et al. *Landscape analysis for the specimen data refinery.* Research Ideas and Outcomes, 2020.
9. Owen D., Livermore L., et al. *Towards a scientific workflow featuring Natural Language Processing for the digitisation of natural history collections.* Research Ideas and Outcomes, 2020.
10. Guralnick R., et al. *Towards instructable, generalisable VLMs for label transcription of biodiversity specimens.* 2024.
11. Smith R. *An Overview of the Tesseract OCR Engine.* In Proc. ICDAR, 2007. (Tesseract 5, 2023).
12. Du Y., Chen J. et al. *PaddleOCR: Awesome multilingual OCR toolkit.* PP-OCRv4 / PP-StructureV3, 2023–2024. https://github.com/PaddlePaddle/PaddleOCR
13. Li M., Lv T., et al. *TrOCR: Transformer-based Optical Character Recognition with Pre-trained Models.* AAAI, 2023.
14. Smith R. W. *History of the Tesseract OCR Engine: What Worked and What Didn't.* DRR, 2013.
15. JaidedAI. *EasyOCR.* https://github.com/JaidedAI/EasyOCR (2020–2024).
16. OpenAI. *GPT-4o / GPT-4.1 system card.* 2024.
17. Bai S., Chen K., et al. *Qwen2.5-VL Technical Report.* arXiv:2502.13923, 2025.
18. Kim G., Hong T., et al. *OCR-Free Document Understanding Transformer (Donut).* arXiv:2111.15664; ECCV 2022.
19. Wei H., Liu C., Chen J., et al. *General OCR Theory: Towards OCR-2.0 via a Unified End-to-end Model (GOT-OCR 2.0).* arXiv:2409.01704, 2024.
20. Beyer L., Steiner A., et al. *PaliGemma: A versatile 3B VLM for transfer.* arXiv:2407.07726, 2024.
21. Turnbull R., Fitzgerald E., Thompson K., Birch J. L. *Hespi: A pipeline for automatically detecting information from herbarium specimen sheets.* arXiv:2410.08740; BioScience, 2025. DOI:10.1093/biosci/biaf042.
22. *Index Fungorum.* CABI / Royal Botanic Gardens, Kew. http://www.indexfungorum.org/
23. *MycoBank Database.* International Mycological Association / Westerdijk Institute. https://www.mycobank.org/
24. *GBIF: Global Biodiversity Information Facility.* GBIF Backbone Taxonomy & Occurrence API. https://www.gbif.org/
25. Shorthouse D. P. *Bionomia: linking people and specimens.* https://bionomia.net/
26. Chapman A. D., Wieczorek J. (eds.). *Principles and Methods of Data Cleaning – Primary Species and Species-Occurrence Data.* GBIF, 2020.
27. Wieczorek J., Bloom D., Guralnick R., et al. *Darwin Core: An Evolving Community-Developed Biodiversity Data Standard.* PLoS ONE, 2012.
28. *World Flora Online (WFO).* http://www.worldfloraonline.org/, 2023.

29. Jocher G., Chaurasia A., Qiu J., et al. *Ultralytics YOLOv8 / YOLOv11.* 2023–2024. https://github.com/ultralytics/ultralytics
30. He K., Zhang X., Ren S., Sun J. *Deep Residual Learning for Image Recognition.* CVPR, 2016.
31. Liu Z., Hu H., et al. *Swin Transformer V2: Scaling Up Capacity and Resolution.* CVPR, 2022.
32. Dillen M., Groom Q., et al. *A benchmark dataset of herbarium specimen images with label data.* Biodiversity Data Journal, 2019.
33. Wen J., et al. *Automated information extraction from plant specimen labels using OCR and Large Language Models.* Biodiversity Data Journal, 2025. Code: https://github.com/JW135/Herbarium-OCR-LLM-Pipeline
34. DeepSeek-AI. *DeepSeek-V3 Technical Report.* arXiv:2412.19437, 2024.
35. Haston E., Cubey R., Harpke D. *Data concepts and their relevance for data capture in large scale digitisation of biological collections.* International Journal of Humanities and Arts Computing, 2012; Haston 2015.
36. Drinkwater R. E., Cubey R. W. N., Haston E. M. *The use of Optical Character Recognition (OCR) in the digitisation of herbarium specimen labels.* PhytoKeys, 2014.
37. Alzuru I., Matsunaga A., Tsugawa M., Fortes J. A. B. *Quality-aware human-machine text extraction for biocollections using OCR.* IEEE eScience, 2016.
38. Milleville K., Verstockt S., et al. *Automatic Extraction of Specimens from Multi-Specimen Herbaria.* J. Comput. Cult. Herit., 2023.
39. Weaver W. N., Smith S. A. *From leaves to labels: Building modular machine-learning networks for rapid herbarium specimen analysis with LeafMachine2 / GPT-4V approaches.* Applications in Plant Sciences, 2023–2024.
40. Zhao Y., Lv W., Xu S., et al. *DETRs Beat YOLOs on Real-time Object Detection (RT-DETR).* CVPR, 2024.
41. Zhao Z., Kang Z., et al. *DocLayout-YOLO: Enhancing Document Layout Analysis through Diverse Synthetic Data and Global-to-Local Adaptive Perception.* arXiv:2410.12628, 2024.
42. Liu S., Zeng Z., Ren T., et al. *Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection.* arXiv:2303.05499, 2023.
43. Ravi N., Gabeur V., et al. *SAM 2: Segment Anything in Images and Videos.* Meta AI, 2024.
44. Paruchuri V. *Surya OCR.* https://github.com/VikParuchuri/surya, 2024.
45. Mindee. *docTR: Document Text Recognition.* https://github.com/mindee/doctr, 2021–2024.
46. Kiessling B. *Kraken — a Universal Text Recogniser for HTR.* https://kraken.re/
47. Wick C., Reul C., Puppe F. *Calamari — A High-Performance Tensorflow-based Deep Learning Package for OCR.* Digital Humanities Quarterly, 2020.
48. Puigcerver J. *Are Multidimensional Recurrent Layers Really Necessary for Handwritten Text Recognition?* (PyLaia) ICDAR, 2017.
49. Kahle P., Colutto S., Hackl G., Mühlberger G. *Transkribus — a Service Platform for Transcription, Recognition and Retrieval of Historical Documents.* ICDAR-OST, 2017.
50. Xiao B., Wu H., et al. *Florence-2: Advancing a Unified Representation for a Variety of Vision Tasks.* arXiv:2311.06242, Microsoft, 2024.
51. Yang A., Bai J., et al. *Qwen2.5 Technical Report.* arXiv:2412.15115, 2024.
52. Blecher L., Cucurull G., Scialom T., Stojnic R. *Nougat: Neural Optical Understanding for Academic Documents.* arXiv:2308.13418, Meta, 2023.
53. Chen Z., Wu J., et al. *InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks; InternVL 2.5 / 3.* CVPR 2024; 2024–2025.
54. Yao Y., Yu T., et al. *MiniCPM-V: A GPT-4V Level MLLM on Your Phone.* arXiv:2408.01800, 2024.
55. Meta AI. *Llama 3.2 Vision.* 2024. https://ai.meta.com/llama/
56. Steiner A., et al. *PaliGemma 2: A Family of Versatile VLMs for Transfer.* arXiv:2412.03555, 2024.
57. Anthropic. *Claude 3.5 / Claude 4 model card.* 2024–2025.
58. Google DeepMind. *Gemini 2.0 / 2.5 Pro technical report.* 2024–2025.

59. Kwon W., Li Z., Zhuang S., et al. *Efficient Memory Management for Large Language Model Serving with PagedAttention (vLLM).* SOSP, 2023.
60. Zheng L., Yin L., et al. *SGLang: Efficient Execution of Structured Language Model Programs.* arXiv:2312.07104, 2023.
61. Mathew M., Karatzas D., Jawahar C. V. *DocVQA: A Dataset for VQA on Document Images.* WACV, 2021.
62. Fu C., et al. *OCRBench v2: An Improved Benchmark for Evaluating Large Multimodal Models on Visual Text Localization and Reasoning.* 2024.
63. Zhu J., et al. *MMDocBench: Benchmarking Large Vision-Language Models for Fine-Grained Visual Document Understanding.* 2024.
64. Willard B., Louf R. *Efficient Guided Generation for Large Language Models (Outlines).* arXiv:2307.09702, 2023.
65. Liu J. *Instructor: Structured outputs powered by LLMs.* https://github.com/jxnl/instructor, 2023.
66. Little D. P. *Recognition of Latinized Scientific Names with NLP — Quaesitor.* Biodiversity Data Journal, 2020.
67. Zaratiana U., Tomeh N., Holat P., Charnois T. *GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer.* NAACL, 2024.
68. Bánki O., et al. *Catalogue of Life Checklist.* https://www.catalogueoflife.org/
69. Schoch C. L., et al. *NCBI Taxonomy: a comprehensive update on curation, resources and tools.* Database, 2020.
70. Harvard University Herbaria. *Index of Botanists.* https://huh.harvard.edu/botanists
71. *JSTOR Global Plants.* https://plants.jstor.org/
72. Wick M. *GeoNames Geographical Database.* https://www.geonames.org/
73. *Nominatim — OpenStreetMap geocoder.* https://nominatim.org/
74. Mapzen / Linux Foundation. *Pelias geocoder.* https://pelias.io/
75. Vrandečić D., Krötzsch M. *Wikidata: A Free Collaborative Knowledgebase.* CACM, 2014.
76. J. Paul Getty Trust. *Getty Thesaurus of Geographic Names (TGN).* http://www.getty.edu/research/tools/vocabularies/tgn/
77. Mostern R., Berman M. L., et al. *The World Historical Gazetteer.* University of Pittsburgh. https://whgazetteer.org/
78. Zizka A., Silvestro D., et al. *CoordinateCleaner: Standardized cleaning of occurrence records from biological collection databases.* Methods in Ecology and Evolution, 2019.
79. Ribeiro B. R., Velazco S. J. E., et al. *bdc: A toolkit for standardizing, integrating and cleaning biodiversity data.* Methods in Ecology and Evolution, 2022.
80. Guo C., Pleiss G., Sun Y., Weinberger K. Q. *On Calibration of Modern Neural Networks.* ICML, 2017.
81. Wang X., Wei J., et al. *Self-Consistency Improves Chain of Thought Reasoning in Language Models.* ICLR, 2023.
82. Zheng L., Chiang W.-L., et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena.* NeurIPS, 2023.
83. LangChain Inc. *LangGraph: Stateful, multi-actor agents with LLMs.* https://github.com/langchain-ai/langgraph, 2024.
84. *Pydantic-AI.* https://github.com/pydantic/pydantic-ai, 2024.
85. Hugging Face. *smolagents.* https://github.com/huggingface/smolagents, 2024.
86. Liu J., et al. *LlamaIndex: A data framework for LLM applications.* https://github.com/run-llama/llama_index
87. Anthropic. *Model Context Protocol (MCP).* https://modelcontextprotocol.io/, 2024.
88. McAleese N., et al. *LLM Critics Help Catch LLM Bugs (CriticGPT).* OpenAI, 2024.
89. Shinn N., Cassano F., Berman R., et al. *Reflexion: Language Agents with Verbal Reinforcement Learning.* NeurIPS, 2023.
90. Wang X., Xie L., Dong C., Shan Y. *Real-ESRGAN: Training Real-World Blind Super-Resolution with*

Pure Synthetic Data. ICCV Workshops, 2021.
91. Liang J., Cao J., et al. *SwinIR: Image Restoration Using Swin Transformer.* ICCV Workshops, 2021.
92. *Pydantic v2.* https://docs.pydantic.dev/
93. Sauvola J., Pietikäinen M. *Adaptive document image binarization.* Pattern Recognition, 2000.
94. Brown T., Mann B., et al. *Language Models are Few-Shot Learners (GPT-3).* NeurIPS, 2020.
95. Settles B. *Active Learning Literature Survey.* University of Wisconsin–Madison, 2010.
96. Danka T. *modAL: A modular active learning framework for Python.* JOSS, 2018.
97. Hu E. J., Shen Y., et al. *LoRA: Low-Rank Adaptation of Large Language Models.* ICLR, 2022.
98. Hinton G., Vinyals O., Dean J. *Distilling the Knowledge in a Neural Network.* NIPS Deep Learning Workshop, 2014.
99. Ratcliff J. W., Metzener D. E. *Pattern Matching: The Gestalt Approach.* Dr. Dobb's Journal, 1988.
100. Huang L., Yu W., et al. *A Survey on Hallucination in Large Language Models.* arXiv:2311.05232, 2023.
101. Wilkinson M. D., Dumontier M., et al. *The FAIR Guiding Principles for scientific data management and stewardship.* Scientific Data, 2016.